

# 多元统计

陈崇双

西南交通大学数学学院统计系

[ccsmars@swjtu.edu.cn](mailto:ccsmars@swjtu.edu.cn)

2018-2019学年

## 1 对应分析

- 对应分析的必要性
- 联列表
- 基本理论

# 第一节：对应分析的必要性

因子分析类型：

- R型因子分析: 研究变量之间的相关关系
- Q型因子分析: 研究样本之间的相关关系

每种类型的因子分析，**单独**从一个角度（变量或者样本）去分析数据的信息，不能厘清之间的关系。

# 第一节：对应分析的必要性

因子分析类型：

- R型因子分析: 研究变量之间的相关关系
- Q型因子分析: 研究样本之间的相关关系

每种类型的因子分析，**单独**从一个角度（变量或者样本）去分析数据的信息，不能厘清之间的关系。对应分析**结合**了两种类型因子分析，同时对数据表中的行与列进行降维处理，简化了数据结构，如以二维图形表示数据表中行与列之间的关系。

# 对应分析的必要性

对应分析的思想，由M. W. Richardson和G. F. Kuder提出，日本统计学家Chikio Hayashi和法国统计学家Jean-Paul Benzécri发展了该方法。

M. W. Richardson, G. F. Kuder (1933). Making a rating scale that measures. *Personnel Journal*, 12:36-40.

<https://psycnet.apa.org/record/1933-04735-001>

Chikio Hayashi(1952). On the prediction of phenomena from qualitative data and the quantification of qualitative data from the mathematical statistical point of view. *Annals of the Institute of Statistical Mathematics*,3(1): 69-98. <https://ci.nii.ac.jp/naid/30040356125>

Jean-Paul Benzécri (1969). Statistical analysis as a tool to make patterns emerge from data. *Methodologies of Pattern Recognition*, 35-74. <https://ci.nii.ac.jp/naid/10006680234>

## 第二节：联列表

联列表：描述属性变量（定类尺度或定序尺度）的各种状态或相关关系，在调查研究中尤为普遍。

# 联列表

例：为了了解消费者对自己产品的满意情况，针对不同职业的消费者进行了调查。调查数据整理如下表所示。

职业 \ 评价	非常满意	比较满意	一般	不太满意	不满意	汇总
一般工人						
管理者						
行政官员						
.....						
汇总						

# 联列表

例：为了了解消费者对自己产品的满意情况，针对不同职业的消费者进行了调查。调查数据整理如下表所示。

职业 \ 评价	非常满意	比较满意	一般	不太满意	不满意	汇总
一般工人						
管理者						
行政官员						
.....						
汇总						

该表可看出：调查对象的职业构成、整体评价、职业分布与评价之间的相关关系。具体地，行列交叉的某个数值越大，表明该类职业与该类评价等级有较强的相关性。



# 联列表

一般地，假设研究对象有两个属性。其中属性 $A$ 有 $r$ 类，分别记为 $A_1, A_2, \dots, A_r$ ，属性 $B$ 有 $s$ 类，分别记为 $B_1, B_2, \dots, B_s$ 。属于状态 $A_i$ 和 $B_j$ 共同的样本数为 $n_{i,j}$ ,  $i = 1, 2, \dots, r, j = 1, 2, \dots, s$ 。汇总如下表。

	$B_1$	$\dots$	$B_j$	$\dots$	$B_s$	合计
$A_1$	$n_{1,1}$	$\dots$	$n_{1,j}$	$\dots$	$n_{1,s}$	$n_{1.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$A_i$	$n_{i,1}$	$\dots$	$n_{i,j}$	$\dots$	$n_{i,s}$	$n_{i.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$A_r$	$n_{r,1}$	$\dots$	$n_{r,j}$	$\dots$	$n_{r,s}$	$n_{r.}$
合计	$n_{.1}$	$\dots$	$n_{.j}$	$\dots$	$n_{.s}$	$n$

# 联列表

状态 $A_i$ 的样本数为 $n_{i.} = \sum_{j=1}^s n_{i,j}$ , 状态 $B_j$ 的样本数为 $n_{.j} = \sum_{i=1}^r n_{i,j}$ , 总样本数为 $n = \sum_{i=1}^r \sum_{j=1}^s n_{i,j}$ 。为了方便地表示两个属性各个状态之间的关系, 往往用频率代替频数, 即 $p_{i,j} = n_{i,j}/n$ 。

	$B_1$	$\cdots$	$B_j$	$\cdots$	$B_s$	合计
$A_1$	$p_{1,1}$	$\cdots$	$p_{1,j}$	$\cdots$	$p_{1,s}$	$p_{1.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$A_i$	$p_{i,1}$	$\cdots$	$p_{i,j}$	$\cdots$	$p_{i,s}$	$p_{i.}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$A_r$	$p_{r,1}$	$\cdots$	$p_{r,j}$	$\cdots$	$p_{r,s}$	$p_{r.}$
合计	$p_{.1}$	$\cdots$	$p_{.j}$	$\cdots$	$p_{.s}$	1

# 联列表

引入矩阵。

$$\mathbf{P} = \begin{pmatrix} p_{1,1} & \cdots & p_{1,j} & \cdots & p_{1,s} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ p_{i,1} & \cdots & p_{i,j} & \cdots & p_{i,s} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ p_{r,1} & \cdots & p_{r,j} & \cdots & p_{r,s} \end{pmatrix}, \mathbf{P}_R = \begin{pmatrix} p_{1.} \\ \vdots \\ p_{i.} \\ \vdots \\ p_{r.} \end{pmatrix}, \mathbf{P}_C = \begin{pmatrix} p_{.1} \\ \vdots \\ p_{.j} \\ \vdots \\ p_{.s} \end{pmatrix}$$

则有,  $\mathbf{P} \times \mathbf{1}_r = \mathbf{P}_R$ ,  $\mathbf{P}^\top \times \mathbf{1}_s = \mathbf{P}_C$ .

# 联列表

概率含义解释。若将 $p_{i,j}$ 视为状态 $A_i$ 和 $B_j$ 同时出现的联合概率，则 $p_{i.}$ 表示状态 $A_i$ 的边缘概率， $p_{.j}$ 表示属性 $B_j$ 的边缘概率。

# 联列表

概率含义解释。若将 $p_{i,j}$ 视为状态 $A_i$ 和 $B_j$ 同时出现的联合概率，则 $p_{i\cdot}$ 表示状态 $A_i$ 的边缘概率， $p_{\cdot j}$ 表示属性 $B_j$ 的边缘概率。

考察属性 $A$ 和属性 $B$ 之间的相互关系，可以转化为研究各种状态出现的概率。例如，若二者之间相互独立，则下式成立

$$p_{i,j} = p_{i\cdot} \times p_{\cdot j}, i = 1, 2, \dots, r, j = 1, 2, \dots, s$$

# 联列表

概率含义解释。若将 $p_{i,j}$ 视为状态 $A_i$ 和 $B_j$ 同时出现的联合概率，则 $p_{i\cdot}$ 表示状态 $A_i$ 的边缘概率， $p_{\cdot j}$ 表示属性 $B_j$ 的边缘概率。

考察属性 $A$ 和属性 $B$ 之间的相互关系，可以转化为研究各种状态出现的概率。例如，若二者之间相互独立，则下式成立

$$p_{i,j} = p_{i\cdot} \times p_{\cdot j}, i = 1, 2, \dots, r, j = 1, 2, \dots, s$$

由此可得，状态 $A_i$ 和 $B_j$ 同时出现的概率的估计

$$\hat{p}_{i,j} = p_{i\cdot} \times p_{\cdot j}, i = 1, 2, \dots, r, j = 1, 2, \dots, s$$

# 联列表

概率含义解释。若将 $p_{i,j}$ 视为状态 $A_i$ 和 $B_j$ 同时出现的联合概率，则 $p_{i\cdot}$ 表示状态 $A_i$ 的边缘概率， $p_{\cdot j}$ 表示属性 $B_j$ 的边缘概率。

考察属性 $A$ 和属性 $B$ 之间的相互关系，可以转化为研究各种状态出现的概率。例如，若二者之间相互独立，则下式成立

$$p_{i,j} = p_{i\cdot} \times p_{\cdot j}, i = 1, 2, \dots, r, j = 1, 2, \dots, s$$

由此可得，状态 $A_i$ 和 $B_j$ 同时出现的概率的估计

$$\hat{p}_{i,j} = p_{i\cdot} \times p_{\cdot j}, i = 1, 2, \dots, r, j = 1, 2, \dots, s$$

实际概率 $p_{i,j}$ 与期望概率 $\hat{p}_{i,j}$ 的差别大小，可以判断两属性是否独立。

# 联列表

采用假设检验的方法进行量化研究。

- ① 提出原假设 $H_0$ :属性A和属性B相互独立; 备择假设 $H_1$ :属性A和属性B不独立;

- ② 当原假设 $H_0$ 成立时, 检验统计量

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{[n_{i,j} - n_{i.}n_{.j}/n]^2}{n_{i.}n_{.j}/n} = n \sum_{i=1}^r \sum_{j=1}^s \frac{[p_{i,j} - p_{i.}p_{.j}]^2}{p_{i.}p_{.j}}$$

近似服从自由度为 $(r-1)(s-1)$ 的 $\chi^2$ 分布;

- ③ 计算检验统计量的观察值 $\chi^2$ , 如果 $\chi^2 > \chi_{\alpha}^2((r-1)(s-1))$ , 则在显著性水平 $\alpha$ 下拒绝原假设。



注1：检验统计量刻画了实际频数（频率）与理论频数（频率）之间相对偏差的总加权和，其中权为理论频数（频率）。

# 联列表

注1：检验统计量刻画了实际频数（频率）与理论频数（频率）之间相对偏差的总加权和，其中权为理论频数（频率）。

注2：如果属性变量的取值类别较多，可能导致 $p_{i\cdot}$ 或 $p_{\cdot j}$ 相对较小，从而影响检验统计量的观察值 $\chi^2$ 。

# 联列表

注1：检验统计量刻画了实际频数（频率）与理论频数（频率）之间相对偏差的总加权和，其中权为理论频数（频率）。

注2：如果属性变量的取值类别较多，可能导致 $p_{i.}$ 或 $p_{.j}$ 相对较小，从而影响检验统计量的观察值 $\chi^2$ 。

注3：联列表可分析属性变量之间的独立性，对于连续性变量按照某种规则分段也适用。

# 联列表

注1：检验统计量刻画了实际频数（频率）与理论频数（频率）之间相对偏差的总加权和，其中权为理论频数（频率）。

注2：如果属性变量的取值类别较多，可能导致 $p_{i.}$ 或 $p_{.j}$ 相对较小，从而影响检验统计量的观察值 $\chi^2$ 。

注3：联列表可分析属性变量之间的独立性，对于连续性变量按照某种规则分段也适用。

注4：如果拒绝了独立性假设，进一步还希望知道属性变量各状态间的相关关系，则需进行对应分析。

### 第三节：基本理论

当属性 $A$ 和 $B$ 的类别较少时，如果 $A_i$ 和 $B_j$ 两个状态同时出现的联合概率 $p_{i,j}$ 相对较大，则说明二者有较强的依赖关系。

### 第三节：基本理论

当属性 $A$ 和 $B$ 的类别较少时，如果 $A_i$ 和 $B_j$ 两个状态同时出现的联合概率 $p_{i,j}$ 相对较大，则说明二者有较强的依赖关系。但当属性 $A$ 和 $B$ 的类别较多时，很难做出正确判断，此时需要通过降维简化联列表的结构。

### 第三节：基本理论

当属性 $A$ 和 $B$ 的类别较少时，如果 $A_i$ 和 $B_j$ 两个状态同时出现的联合概率 $p_{i,j}$ 相对较大，则说明二者有较强的依赖关系。但当属性 $A$ 和 $B$ 的类别较多时，很难做出正确判断，此时需要通过降维简化联列表的结构。

对应分析利用降维的思想，在一张二维图上同时表示两类属性变量的各种状态，直观地描述原始数据的结构。

对应分析的数据：频率的联列表。

## 定义1

当给定状态 $A_i$ 的条件下，属性 $B$ 各个状态发生的条件概率构成的向量称之为**行剖面**，记为 $\mathbf{P}_i^R = \left( \frac{p_{i,1}}{p_{i.}}, \dots, \frac{p_{i,s}}{p_{i.}} \right)^T$ 。



对应分析的数据：频率的联列表。

## 定义1

当给定状态 $A_i$ 的条件下，属性 $B$ 各个状态发生的条件概率构成的向量称之为**行剖面**，记为 $\mathbf{P}_i^R = (\frac{p_{i,1}}{p_{i.}}, \dots, \frac{p_{i,s}}{p_{i.}})^T$ 。

注：由于 $\sum_{j=1}^s \frac{p_{i,j}}{p_{i.}} = 1$ 恒成立。如果将属性 $B$ 各个状态发生的条件概率视为 $s$ 维空间的一个点，那么这些点分布在 $s$ 维空间中的一个面上。

# 基本理论

基于条件概率，引入距离描述属性不同状态之间的疏远程度。

## 定义2

属性 $A$ 的状态 $A_k$ 和 $A_l$ 之间的加权欧式距离为

$$D(A_k, A_l)^2 = \sum_{j=1}^s \frac{1}{p_{.j}} \left( \frac{p_{k,j}}{p_{k.}} - \frac{p_{l,j}}{p_{l.}} \right)^2 = \sum_{j=1}^s \left( \frac{p_{k,j}}{p_{k.} \sqrt{p_{.j}}} - \frac{p_{l,j}}{p_{l.} \sqrt{p_{.j}}} \right)^2$$

# 基本理论

基于条件概率，引入距离描述属性不同状态之间的疏远程度。

## 定义2

属性A的状态 $A_k$ 和 $A_l$ 之间的加权欧式距离为

$$D(A_k, A_l)^2 = \sum_{j=1}^s \frac{1}{p_{\cdot j}} \left( \frac{p_{k,j}}{p_{k\cdot}} - \frac{p_{l,j}}{p_{l\cdot}} \right)^2 = \sum_{j=1}^s \left( \frac{p_{k,j}}{p_{k\cdot} \sqrt{p_{\cdot j}}} - \frac{p_{l,j}}{p_{l\cdot} \sqrt{p_{\cdot j}}} \right)^2$$

注1：式中属性B各个状态的边缘概率的倒数为权。原因在于，当状态 $B_j$ 出现的边缘概率较大时，则 $\left( \frac{p_{k,j}}{p_{k\cdot}} - \frac{p_{l,j}}{p_{l\cdot}} \right)^2$ 的贡献就被高估了。

# 基本理论

基于条件概率，引入距离描述属性不同状态之间的疏远程度。

## 定义2

属性 $A$ 的状态 $A_k$ 和 $A_l$ 之间的加权欧式距离为

$$D(A_k, A_l)^2 = \sum_{j=1}^s \frac{1}{p_{.j}} \left( \frac{p_{k,j}}{p_{k.}} - \frac{p_{l,j}}{p_{l.}} \right)^2 = \sum_{j=1}^s \left( \frac{p_{k,j}}{p_{k.} \sqrt{p_{.j}}} - \frac{p_{l,j}}{p_{l.} \sqrt{p_{.j}}} \right)^2$$

注1：式中属性 $B$ 各个状态的边缘概率的倒数为权。原因在于，当状态 $B_j$ 出现的边缘概率较大时，则 $\left(\frac{p_{k,j}}{p_{k.}} - \frac{p_{l,j}}{p_{l.}}\right)^2$ 的贡献就被高估了。

注2：加权距离相当于行剖面的坐标修正为 $\left(\frac{p_{i,1}}{p_{i.} \sqrt{p_{.1}}}, \dots, \frac{p_{i,s}}{p_{i.} \sqrt{p_{.s}}}\right)^T$ ， $i = 1, 2, \dots, r$ 。

# 基本理论

若要刻画属性A各种状态的总差异，需引入“重心”概念。

## 定义3

属性A的重心, 为行剖面修正坐标的加权平均

$$\begin{aligned}\overline{\mathbf{P}^R} &= \left( \sum_{i=1}^r p_{i.} \frac{p_{i,1}}{\sqrt{p_{.1}}}, \dots, \sum_{i=1}^r p_{i.} \frac{p_{i,s}}{\sqrt{p_{.s}}} \right)^T \\ &= \left( \sqrt{p_{.1}}, \dots, \sqrt{p_{.s}} \right)^T\end{aligned}$$

# 基本理论

若要刻画属性A各种状态的总差异，需引入“重心”概念。

## 定义3

属性A的重心，为行剖面修正坐标的加权平均

$$\begin{aligned}\overline{\mathbf{P}}^R &= \left( \sum_{i=1}^r p_{i.} \frac{p_{i,1}}{p_{i.} \sqrt{p_{.1}}}, \dots, \sum_{i=1}^r p_{i.} \frac{p_{i,s}}{p_{i.} \sqrt{p_{.s}}} \right)^T \\ &= \left( \sqrt{p_{.1}}, \dots, \sqrt{p_{.s}} \right)^T\end{aligned}$$

注：行剖面修正坐标的每个分量，刻画了给定状态 $A_i$ 时状态 $B_j$ 发生的条件概率，消除了状态 $A_i$ 出现的概率影响。重心以此概率为权求平均。

## 定义4

属性A各状态相对于重心的加权距离总和, 即总惯量

$$\begin{aligned} I^R &= \sum_{i=1}^r p_i \cdot D(\mathbf{P}_i^R, \overline{\mathbf{P}}^R)^2 \\ &= \sum_{i=1}^r \sum_{j=1}^s p_i \cdot \left( \frac{p_{i,j}}{p_i \cdot \sqrt{p_{\cdot j}}} - \sqrt{p_{\cdot j}} \right)^2 \\ &= \sum_{i=1}^r \sum_{j=1}^s \frac{(p_{i,j} - p_i \cdot p_{\cdot j})^2}{p_i \cdot p_{\cdot j}} \end{aligned}$$

## 定义4

属性A各状态相对于重心的加权距离总和, 即总惯量

$$\begin{aligned} I^R &= \sum_{i=1}^r p_{i.} D(\mathbf{p}_i^R, \overline{\mathbf{p}}^R)^2 \\ &= \sum_{i=1}^r \sum_{j=1}^s p_{i.} \left( \frac{p_{i,j}}{p_{i.} \sqrt{p_{.j}}} - \sqrt{p_{.j}} \right)^2 \\ &= \sum_{i=1}^r \sum_{j=1}^s \frac{(p_{i,j} - p_{i.} p_{.j})^2}{p_{i.} p_{.j}} \end{aligned}$$

注: 总惯量刻画了属性各状态的差异, 且  $I^R = \frac{1}{n} \chi^2$ 。



类似地，也可以按照列进行上述定义。

类似地，也可以按照列进行上述定义。

## 定义5

当给定状态 $B_j$ 的条件下，属性 $A$ 各个状态发生的条件概率构成的向量称之为**列剖面**，记为 $\mathbf{P}_j^C = (\frac{p_{1j}}{p_{\cdot j}}, \dots, \frac{p_{rj}}{p_{\cdot j}})^T$ 。

# 基本理论

类似地，也可以按照列进行上述定义。

## 定义5

当给定状态 $B_j$ 的条件下，属性 $A$ 各个状态发生的条件概率构成的向量称之为**列剖面**，记为 $\mathbf{P}_j^C = (\frac{p_{1,j}}{p_{\cdot,j}}, \dots, \frac{p_{r,j}}{p_{\cdot,j}})^T$ 。

## 定义6

属性 $B$ 的状态 $B_k$ 和 $B_l$ 之间的加权欧式距离为

$$D(B_k, B_l)^2 = \sum_{i=1}^r \frac{1}{p_{i\cdot}} \left( \frac{p_{i,k}}{p_{\cdot,k}} - \frac{p_{i,l}}{p_{\cdot,l}} \right)^2 = \sum_{i=1}^r \left( \frac{p_{i,k}}{p_{\cdot,k} \sqrt{p_{i\cdot}}} - \frac{p_{i,l}}{p_{\cdot,l} \sqrt{p_{i\cdot}}} \right)^2$$

## 定义7

属性 $B$ 的重心为

$$\overline{\mathbf{P}^C} = \left( \sum_{j=1}^s p_{.j} \frac{p_{1,j}}{p_{.j} \sqrt{p_{1.}}}, \dots, \sum_{j=1}^s p_{.j} \frac{p_{r,j}}{p_{.j} \sqrt{p_{r.}}} \right)^T = (\sqrt{p_{1.}}, \dots, \sqrt{p_{r.}})^T$$

# 基本理论

## 定义7

属性 $B$ 的重心为

$$\overline{\mathbf{P}}^C = \left( \sum_{j=1}^s p_{.j} \frac{p_{1,j}}{p_{.j} \sqrt{p_{1.}}}, \dots, \sum_{j=1}^s p_{.j} \frac{p_{r,j}}{p_{.j} \sqrt{p_{r.}}} \right)^T = (\sqrt{p_{1.}}, \dots, \sqrt{p_{r.}})^T$$

## 定义8

属性 $B$ 各状态相对于重心的加权距离总和为

$$\begin{aligned} I^C &= \sum_{i=1}^r \sum_{j=1}^s p_{.j} \left( \frac{p_{i,j}}{p_{.j} \sqrt{p_{i.}}} - \sqrt{p_{i.}} \right)^2 \\ &= \sum_{i=1}^r \sum_{j=1}^s \frac{(p_{i,j} - p_{i.} p_{.j})^2}{p_{i.} p_{.j}} \end{aligned}$$

经过以上分析，对行（列）剖面各点进行变换，计算加权距离来刻画某个属性各个状态之间的接近程度。

经过以上分析，对行（列）剖面各点进行变换，计算加权距离来刻画某个属性各个状态之间的接近程度。例如，距离较短的两个状态可化为同一类，反之化为不同的类，分类达到简化数据结构的目的。

经过以上分析，对行（列）剖面各点进行变换，计算加权距离来刻画某个属性各个状态之间的接近程度。例如，距离较短的两个状态可化为同一类，反之化为不同的类，分类达到简化数据结构的目的。

该做法不能实现对两个属性同时进行分析。对应分析不求距离而求协方差，然后提取主因子，对两个属性的各状态进行分析。



# 基本理论

对行剖面进行分析。

为消除属性***B***各状态发生的边缘概率的影响，对每个行剖面的坐标修正，相当于进行变换

$$\left( \frac{p_{i,1}}{p_{i.}\sqrt{p_{.1}}}, \dots, \frac{p_{i,s}}{p_{i.}\sqrt{p_{.s}}} \right) = \left( \frac{p_{i,1}}{p_{i.}}, \dots, \frac{p_{i,s}}{p_{i.}} \right) \text{diag}(\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}) \\ \triangleq (\mathbf{P}_i^R)^\top \Phi^R$$

其中  $\Phi^R = \text{diag}(\sqrt{p_{.1}}, \sqrt{p_{.2}}, \dots, \sqrt{p_{.s}})$ 。

# 基本理论

对行剖面进行分析。

为消除属性 $B$ 各状态发生的边缘概率的影响，对每个行剖面的坐标修正，相当于进行变换

$$\left( \frac{p_{i,1}}{p_{i.}\sqrt{p_{.1}}}, \dots, \frac{p_{i,s}}{p_{i.}\sqrt{p_{.s}}} \right) = \left( \frac{p_{i,1}}{p_{i.}}, \dots, \frac{p_{i,s}}{p_{i.}} \right) \text{diag}(\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}) \\ \triangleq (\mathbf{P}_i^R)^\top \Phi^R$$

其中 $\Phi^R = \text{diag}(\sqrt{p_{.1}}, \sqrt{p_{.2}}, \dots, \sqrt{p_{.s}})$ 。从而行剖面构成一个新的矩阵

$$\begin{pmatrix} (\mathbf{P}_1^R)^\top \Phi^R \\ \vdots \\ (\mathbf{P}_r^R)^\top \Phi^R \end{pmatrix}$$

# 基本理论

对应的加权协差阵为 $s$ 阶方阵,

$$\Sigma^R = \sum_{i=1}^r p_i. [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]^\top [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]$$

# 基本理论

对应的加权协差阵为 $s$ 阶方阵,

$$\Sigma^R = \sum_{i=1}^r p_i. [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]^\top [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]$$

同时, 对于任意的 $i = 1, 2, \dots, r$ 满足

$$\begin{aligned} & [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top] \overline{\mathbf{P}^R} \\ &= \left[ \frac{p_{i,1}}{p_{i.}\sqrt{p_{.1}}} - \sqrt{p_{.1}}, \dots, \frac{p_{i,s}}{p_{i.}\sqrt{p_{.s}}} - \sqrt{p_{.s}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= \left[ \frac{p_{i,1} - p_{i.}p_{.1}}{p_{i.}\sqrt{p_{.1}}}, \dots, \frac{p_{i,s} - p_{i.}p_{.s}}{p_{i.}\sqrt{p_{.s}}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= 0 \end{aligned}$$

# 基本理论

对应的加权协差阵为 $s$ 阶方阵,

$$\Sigma^R = \sum_{i=1}^r p_i. [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]^\top [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]$$

同时, 对于任意的 $i = 1, 2, \dots, r$ 满足

$$\begin{aligned} & [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top] \overline{\mathbf{P}^R} \\ &= \left[ \frac{p_{i,1}}{p_{i.}\sqrt{p_{.1}}} - \sqrt{p_{.1}}, \dots, \frac{p_{i,s}}{p_{i.}\sqrt{p_{.s}}} - \sqrt{p_{.s}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= \left[ \frac{p_{i,1} - p_{i.}p_{.1}}{p_{i.}\sqrt{p_{.1}}}, \dots, \frac{p_{i,s} - p_{i.}p_{.s}}{p_{i.}\sqrt{p_{.s}}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= 0 \end{aligned}$$

因而有 $\Sigma^R \overline{\mathbf{P}^R} = 0 \times \overline{\mathbf{P}^R} = \mathbf{0}$ ,

# 基本理论

对应的加权协差阵为 $s$ 阶方阵,

$$\Sigma^R = \sum_{i=1}^r p_i. [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]^\top [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top]$$

同时, 对于任意的 $i = 1, 2, \dots, r$ 满足

$$\begin{aligned} & [(\mathbf{P}_i^R)^\top \Phi^R - (\overline{\mathbf{P}^R})^\top] \overline{\mathbf{P}^R} \\ &= \left[ \frac{p_{i,1}}{p_{i,1} \sqrt{p_{.1}}} - \sqrt{p_{.1}}, \dots, \frac{p_{i,s}}{p_{i,s} \sqrt{p_{.s}}} - \sqrt{p_{.s}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= \left[ \frac{p_{i,1} - p_{i,1} p_{.1}}{p_{i,1} \sqrt{p_{.1}}}, \dots, \frac{p_{i,s} - p_{i,s} p_{.s}}{p_{i,s} \sqrt{p_{.s}}} \right] [\sqrt{p_{.1}}, \dots, \sqrt{p_{.s}}]^\top \\ &= 0 \end{aligned}$$

因而有 $\Sigma^R \overline{\mathbf{P}^R} = 0 \times \overline{\mathbf{P}^R} = \mathbf{0}$ , 意味着重心 $\overline{\mathbf{P}^R}$ 是协差阵的特征值为0所对应的特征向量。

# 基本理论

$\Sigma^R$ 的代表元素为

$$\begin{aligned} a_{i,j} &= \sum_{k=1}^r p_{k.} \left( \frac{p_{k,i}}{p_{k.} \sqrt{p_{.i}}} - \sqrt{p_{.i}} \right) \left( \frac{p_{k,j}}{p_{k.} \sqrt{p_{.j}}} - \sqrt{p_{.j}} \right) \\ &= \sum_{k=1}^r \left( \frac{p_{k,i} - p_{k.} p_{.i}}{\sqrt{p_{k.} p_{.i}}} \right) \left( \frac{p_{k,j} - p_{k.} p_{.j}}{\sqrt{p_{k.} p_{.j}}} \right) \\ &\triangleq \sum_{k=1}^r z_{k,i} z_{k,j} \end{aligned}$$

其中  $z_{i,j} = \frac{p_{i,j} - p_{i.} p_{.j}}{\sqrt{p_{i.} p_{.j}}}$ ,  $i = 1, \dots, r; j = 1, \dots, s$ 。若令  $Z = (z_{i,j})_{r \times s}$ , 则有  $\Sigma^R = Z^T Z$ 。

类似地，也可以对列剖面进行分析。加权协差阵为 $r$ 阶方阵

$$\Sigma^C = \sum_{j=1}^s p_{.j} [(\mathbf{P}_j^C \Phi^C)^\top - (\overline{\mathbf{P}^C})^\top]^\top [(\mathbf{P}_j^C \Phi^C)^\top - (\overline{\mathbf{P}^C})^\top]$$

其中 $\Phi^C = \text{diag}(\sqrt{p_{1.}}, \dots, \sqrt{p_{r.}})$ 。满足

- $\Sigma^C = \mathbf{Z}\mathbf{Z}^\top$ ;
- 重心 $\overline{\mathbf{P}^C} = (\sqrt{p_{1.}}, \dots, \sqrt{p_{r.}})^\top$  是其特征值为0所对应的特征向量。



# 基本理论

根据矩阵知识有,  $s$ 阶方阵 $\Sigma^R = Z^T Z$ 与 $r$ 阶方阵 $\Sigma^C = Z Z^T$

- 有相同的特征根;
- 都有一个零根, 非零特征根最多为 $\min(r, s) - 1$ .

# 基本理论

根据矩阵知识有,  $s$ 阶方阵 $\Sigma^R = Z^T Z$ 与 $r$ 阶方阵 $\Sigma^C = Z Z^T$

- 有相同的特征根;
- 都有一个零根, 非零特征根最多为 $\min(r, s) - 1$ .

不妨记 $\Sigma^R$ 的非零特征根为 $\lambda_1 \geq \cdots \geq \lambda_k$ , 其中 $0 < k \leq \min(r, s) - 1$ , 对应的特征向量分别为 $\xi_1, \cdots, \xi_k$ , 即

$$Z^T Z \xi_i = \Sigma^R \xi_i = \lambda_i \xi_i, i = 1, 2, \cdots, k$$

# 基本理论

根据矩阵知识有,  $s$ 阶方阵 $\Sigma^R = Z^T Z$ 与 $r$ 阶方阵 $\Sigma^C = Z Z^T$

- 有相同的特征根;
- 都有一个零根, 非零特征根最多为 $\min(r, s) - 1$ .

不妨记 $\Sigma^R$ 的非零特征根为 $\lambda_1 \geq \cdots \geq \lambda_k$ , 其中 $0 < k \leq \min(r, s) - 1$ , 对应的特征向量分别为 $\xi_1, \cdots, \xi_k$ , 即

$$Z^T Z \xi_i = \Sigma^R \xi_i = \lambda_i \xi_i, i = 1, 2, \cdots, k$$

上式两边左乘 $Z$ 有,

$$Z Z^T Z \xi_i = \Sigma^C (Z \xi_i) = \lambda_i (Z \xi_i)$$

# 基本理论

根据矩阵知识有,  $s$ 阶方阵 $\Sigma^R = Z^T Z$ 与 $r$ 阶方阵 $\Sigma^C = Z Z^T$

- 有相同的特征根;
- 都有一个零根, 非零特征根最多为 $\min(r, s) - 1$ .

不妨记 $\Sigma^R$ 的非零特征根为 $\lambda_1 \geq \cdots \geq \lambda_k$ , 其中 $0 < k \leq \min(r, s) - 1$ , 对应的特征向量分别为 $\xi_1, \cdots, \xi_k$ , 即

$$Z^T Z \xi_i = \Sigma^R \xi_i = \lambda_i \xi_i, i = 1, 2, \cdots, k$$

上式两边左乘 $Z$ 有,

$$Z Z^T Z \xi_i = \Sigma^C (Z \xi_i) = \lambda_i (Z \xi_i)$$

即 $Z \xi_i$ 为矩阵 $\Sigma^C$ 的特征向量。

注1：对联列表数据做 $Q$ 型因子分析（对属性 $A$ 进行），可方便地得到 $R$ 型因子分析（对属性 $B$ 进行）的结果。

# 基本理论

注1：对联列表数据做 $Q$ 型因子分析（对属性 $A$ 进行），可方便地得到 $R$ 型因子分析（对属性 $B$ 进行）的结果。

注2：原始变量的总方差为行（列）剖面的总惯量；提取公共因子的总方差为特征根之和，显然有 $\mathbf{I}^R = \mathbf{I}^C = \sum_{i=1}^k \lambda_i$ 。

# 基本理论

注1：对联列表数据做 $Q$ 型因子分析（对属性 $A$ 进行），可方便地得到 $R$ 型因子分析（对属性 $B$ 进行）的结果。

注2：原始变量的总方差为行（列）剖面的总惯量；提取公共因子的总方差为特征根之和，显然有 $\mathbf{I}^R = \mathbf{I}^C = \sum_{i=1}^k \lambda_i$ 。

注3：相同数量的公共因子，分别解释两个属性的方差比例相同。一般取2个公共因子，则可在二维图上同时画出两个属性的各个状态。

# 基本理论

注1：对联列表数据做 $Q$ 型因子分析（对属性 $A$ 进行），可方便地得到 $R$ 型因子分析（对属性 $B$ 进行）的结果。

注2：原始变量的总方差为行（列）剖面的总惯量；提取公共因子的总方差为特征根之和，显然有 $\mathbf{I}^R = \mathbf{I}^C = \sum_{i=1}^k \lambda_i$ 。

注3：相同数量的公共因子，分别解释两个属性的方差比例相同。一般取2个公共因子，则可在二维图上同时画出两个属性的各个状态。

注4：对应分析只能直观展示属性之间的关联关系，不能给出关联关系的度量刻画。



# 对应分析步骤

- 1 原始数据整理汇总得到频数的联列表；
- 2 计算频率联列表；
- 3 计算 $Z$ 矩阵；
- 4 由 $\Sigma^R$ （或 $\Sigma^C$ ）对属性 $A$ 进行 $Q$ 型（或 $R$ 型）因子分析，由此导出 $R$ 型（或 $Q$ 型）因子分析的结果；
- 5 在二维图上同时画出属性 $A$ 和 $B$ 各个状态。