

第三章：多元线性回归

主讲人：黄磊

数学学院
西南交通大学

September 26, 2019

Outline

1 多元线性回归模型

- 随机向量补充知识
- 多元线性回归模型
- 回归参数的估计
- 参数估计量的性质
- 回归方程的显著性检验
- 中心化和标准化
- 相关阵和偏相关系数
- 总结与评注

随机向量

在第二章已经看到，当我们把响应变量和解释变量向量化或者矩阵化以后，一元线性回归模型的形式变得非常简单。这一章将进入多元线性回归模型的研究，有必要对随机向量的一些基本性质，作一些介绍和总结。

设 $\mathbf{Y} = (Y_1, \dots, Y_n)^\top$ 为 $n \times 1$ 的随机向量，称

$$E(\mathbf{Y}) = (E(Y_1), \dots, E(Y_n))^\top$$

为 \mathbf{Y} 的均值向量。

Theorem 1

设 \mathbf{A} 为 $m \times n$ 的非随机矩阵， \mathbf{Y} 和 \mathbf{Z} 分别为 $n \times 1$ 和 $m \times 1$ 的随机向量，记 $\boldsymbol{\eta} = \mathbf{A}\mathbf{Y} + \mathbf{Z}$ ，则

$$E(\boldsymbol{\eta}) = \mathbf{A}E(\mathbf{Y}) + E(\mathbf{Z}).$$

随机向量

n 维随机向量 \mathbf{Y} 的协方差阵定义为

$$\text{Cov}(\mathbf{Y}) \stackrel{\text{def}}{=} D(\mathbf{Y}) = E[(\mathbf{Y} - E\mathbf{Y})(\mathbf{Y} - E\mathbf{Y})'],$$

其中 $E\mathbf{Y} = E(\mathbf{Y})$, 为了方便起见。

Proposition 1

$\text{tr}D(\mathbf{Y}) = \sum_{i=1}^n \text{Var}(Y_i)$, 这里 tr 表示方阵的迹, 即对角线元素之和。

Theorem 2

设 \mathbf{Y} 是任意任意 $n \times 1$ 随机向量, 则它的协方差阵 $D(\mathbf{Y})$ 是半正定的对称阵。

Proof 考察任意非随机 $n \times 1$ 向量 \mathbf{c} , 令 $Z = \mathbf{c}'\mathbf{Y}$,

$$\begin{aligned} 0 &\leq \text{Var}(Z) = \text{Var}(\mathbf{c}'\mathbf{Y}) = E(\mathbf{c}'\mathbf{Y} - E\mathbf{c}'\mathbf{Y})^2 \\ &= E(\mathbf{c}'\mathbf{Y} - E\mathbf{c}'\mathbf{Y})(\mathbf{c}'\mathbf{Y} - E\mathbf{c}'\mathbf{Y})' \\ &= \mathbf{c}'E[(\mathbf{Y} - E\mathbf{Y})(\mathbf{Y} - E\mathbf{Y})']\mathbf{c} = \mathbf{c}'D(\mathbf{Y})\mathbf{c}. \end{aligned} \quad (1.1)$$

随机向量

Theorem 3

设 \mathbf{A} 为 $m \times n$ 非随机阵, \mathbf{Y} 为 $n \times 1$ 随机向量, $\mathbf{Z} = \mathbf{A}\mathbf{Y}$, 则

$$D(\mathbf{Z}) = \mathbf{A}D(\mathbf{Y})\mathbf{A}'$$

Proof 根据协方差阵的定义,

$$\begin{aligned} D(\mathbf{Z}) &= E[(\mathbf{Z} - E\mathbf{Z})(\mathbf{Z} - E\mathbf{Z})'] \\ &= E[(\mathbf{A}\mathbf{Y} - E\mathbf{A}\mathbf{Y})(\mathbf{A}\mathbf{Y} - E\mathbf{A}\mathbf{Y})'] \\ &= \mathbf{A}E[(\mathbf{Y} - E\mathbf{Y})(\mathbf{Y} - E\mathbf{Y})']\mathbf{A}' \\ &= \mathbf{A}D(\mathbf{Y})\mathbf{A}'. \end{aligned} \tag{1.2}$$

随机向量

设 \mathbf{Y}_1 和 \mathbf{Y}_2 分别为 $n \times 1$, $m \times 1$ 的随机向量, 定义

$$\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2) = E[(\mathbf{Y}_1 - E\mathbf{Y}_1)(\mathbf{Y}_2 - E\mathbf{Y}_2)']$$

Theorem 4

设 \mathbf{Y}_1 和 \mathbf{Y}_2 分别为 $n \times 1$, $m \times 1$ 的随机向量, \mathbf{A} 和 \mathbf{B} 分别为 $p \times n$ 和 $q \times m$ 的非随机矩阵, 则

$$\text{Cov}(\mathbf{A}\mathbf{Y}_1, \mathbf{B}\mathbf{Y}_2) = \mathbf{A}\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2)\mathbf{B}'$$

Proof

$$\begin{aligned}\text{Cov}(\mathbf{A}\mathbf{Y}_1, \mathbf{B}\mathbf{Y}_2) &= E[(\mathbf{A}\mathbf{Y}_1 - E\mathbf{A}\mathbf{Y}_1)(\mathbf{B}\mathbf{Y}_2 - E\mathbf{B}\mathbf{Y}_2)'] \\ &= \mathbf{A}E[(\mathbf{Y}_1 - E\mathbf{Y}_1)(\mathbf{Y}_2 - E\mathbf{Y}_2)']\mathbf{B}' \\ &= \mathbf{A}\text{Cov}(\mathbf{Y}_1, \mathbf{Y}_2)\mathbf{B}'.\end{aligned}\tag{1.3}$$

矩阵的偏导

Theorem 5

对矩阵 $\mathbf{A} \in R^{n \times p}$, 以及 $\mathbf{X} \in R^p$, 有以下两个结论

$$\frac{\partial \mathbf{A}\mathbf{X}}{\partial \mathbf{X}} = \mathbf{A}', \quad \frac{\partial \mathbf{X}'\mathbf{X}}{\partial \mathbf{X}} = 2\mathbf{X}, \quad (1.4)$$

Theorem 6

复合函数求导— $\mathbf{Z}(\mathbf{Y})$ 是 \mathbf{Y} 的向量函数, $\mathbf{Y}(\mathbf{X})$ 是 \mathbf{X} 的向量函数, 则

$$\frac{\partial \mathbf{Z}}{\partial \mathbf{X}} = \frac{\partial \mathbf{Y}}{\partial \mathbf{X}} \frac{\partial \mathbf{Z}}{\partial \mathbf{Y}} \quad (1.5)$$

于是, 若 \mathbf{A} 是 $n \times p$ 的非随机矩阵, $\mathbf{X} \in R^p$, 则

$$\frac{\partial \{(\mathbf{A}\mathbf{X})'\mathbf{A}\mathbf{X}\}}{\partial \mathbf{X}} = \mathbf{A}'2\mathbf{A}\mathbf{X} = 2\mathbf{A}'\mathbf{A}\mathbf{X}.$$

多元线性回归模型的一般形式

响应变量 y 与解释变量 x_1, x_2, \dots, x_p 的线性回归模型为:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (1.6)$$

$\beta_j, j = 0, \dots, p$ 是 $p+1$ 个未知参数, β_0 是回归常数, $\beta_j, j = 1, \dots, p$ 是回归系数。 $p = 1$ 时就是一元线性回归模型; $p \geq 2$ 时, 就称为多元线性回归模型。与一元线性回归模型一样, 对误差项 ε , 通常假定

$$\begin{cases} E(\varepsilon) = 0 \\ \text{Var}(\varepsilon) = \sigma^2 \end{cases} \quad (1.7)$$

称

$$E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p \quad (1.8)$$

为理论回归方程。

多元线性回归模型的一般形式

对一个实际问题，响应变量和解释变量往往可以获得 n 组观测数据 $\{y_i; x_{1i}, \dots, x_{pi}\} (i = 1, \dots, n)$ ，则通过向量形式，线性回归模型(1.6)可以表示为

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (1.9)$$

其中 $\mathbf{y} = (y_1, \dots, y_n)'$ ， $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_p)$ 称之为 $n \times (p+1)$ 维的**设计矩阵**， $\mathbf{1} = (1, \dots, 1)'$ 是一个 $n \times 1$ 的列向量， $\mathbf{x}_j = (x_{j1}, \dots, x_{jn})'$ 是对应第 j 个**解释变量的观测向量**， $j = 1, \dots, p$ 。 $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)'$ 是 $(p+1) \times 1$ 维的**未知参数向量**， $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)'$ 是 $n \times 1$ 维的**误差项向量**。

基本假定

为了方便地去估计模型的参数以及检验回归方程，需要如下基本假定

- 1 解释变量 $x_j, j = 1, \dots, p$ 是确定性变量（非随机），且 $\text{rank}(\mathbf{X}) = p + 1 < n$ ，即要求 \mathbf{x} 是一个满秩矩阵，其列向量线性无关，样本量个数大于解释变量个数。
- 2 (Gauss-Markov)随机误差项零均值、等方差，即

$$\begin{cases} E(\varepsilon_i) = 0, i = 1, \dots, n \\ \text{Cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j; \quad \text{Var}(\varepsilon_i) = \sigma^2, \end{cases} \quad (1.10)$$

- 3 正态分布假设

$$\begin{cases} \varepsilon_i \sim N(0, \sigma^2), i = 1, \dots, n \\ \varepsilon_1, \dots, \varepsilon_n \text{ 相互独立} \end{cases} \quad (1.11)$$

对于多元线性回归的矩阵形式(1.9)，这个条件也可以表示为 $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ 。由此假设， \mathbf{y} 服从 n 维正态分布， $E(\mathbf{y}) = \mathbf{X}\beta$ ， $\text{Var}(\mathbf{y}) = D(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ ， $\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$

回归方程的解释

以 $p = 2$ 的一个微观经济问题为例子，给出回归方程的几何解释和经济意义。 y 表示空调机销售量， x_1 表示空调机的价格， x_2 表示消费者可支配收入，建立的二元线性回归模型如下

$$\begin{cases} y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon \\ E(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \end{cases} \quad (1.12)$$

在式(1.12)里面，假如保持 x_2 不变，则有

$$\frac{\partial E(y)}{\partial x_1} = \beta_1 \quad (1.13)$$

因此， β_1 可解释为在消费者收入 x_2 保持不变时，空调机价格 x_1 每增加一个单位，空调机销售量 y 的平均增加幅度。类似的，可以解释 β_2 为在空调机价格 x_1 保持不变时，消费者收入 x_2 每增加一个单位，空调机销售量 y 平均增加的幅度。

当 $p > 2$ 时，各个回归系数（也称为偏回归系数）也可以类似地解释。

LSE

根据回归方程矩阵的形式(1.9), 最小二乘估计就是为了寻找使得如下损失函数 $Q(\beta)$ 最小的 $\hat{\beta}$,

$$Q(\beta) = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) \quad (1.14)$$

根据Theorem 5、6的结论, 为了找到 $\hat{\beta}$, 我们可对 $Q(\beta)$ 求关于 β 的一阶偏导, 解方程

$$\frac{\partial Q(\beta)}{\partial \beta} = -\mathbf{X}'2(\mathbf{y} - \mathbf{X}\beta) = -2\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta) = 0 \quad (1.15)$$

整理得 $\mathbf{X}'\mathbf{y} = \mathbf{X}'\mathbf{X}\beta$, 当 $\mathbf{X}'\mathbf{X}$ 的逆存在时, 就可以得到最小二乘估计 $\hat{\beta}$ 为

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, \quad (1.16)$$

另外可求Hessian 矩阵 $\partial^2 Q(\beta)/\partial \beta \partial \beta' = 2\mathbf{X}'\mathbf{X}$, 说明 $\hat{\beta}$ 是 $Q(\beta)$ 的最小值点。

回归值

由以上结论，得经验回归方程

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \stackrel{\text{def}}{=} \mathbf{H}\mathbf{y} \quad (1.17)$$

称 $\hat{\mathbf{y}}$ 为因变量观测值 \mathbf{y} 的回归拟合值，简称回归值或者拟合值。由式(1.17)看到， $\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ 的作用就是把 \mathbf{y} 变为 $\hat{\mathbf{y}}$ ，形式上就是戴了一顶帽子。帽子矩阵 \mathbf{H} 有以下几个特征

- 1 $\mathbf{H}' = \mathbf{H}$, 对称阵
- 2 $\mathbf{H}^2 = \mathbf{H}$, 幂等阵
- 3 \mathbf{v} , \mathbf{H} 投影阵
- 4 $\text{diag}(\mathbf{H}) = (h_{11}, \dots, h_{nn})$,
 $\text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = \text{tr}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}) = p + 1$

残差

称 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ 为 \mathbf{y} 的残差向量, 将 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ 代入, 得

$$\mathbf{e} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I} - \mathbf{H})\mathbf{y},$$

同理, 同学们可以验证, $(\mathbf{I} - \mathbf{H})$ 也是对称阵, 幂等阵。因此,

$$\begin{aligned} D(\mathbf{e}) &= \text{Cov}(\mathbf{e}, \mathbf{e}) \\ &= \text{Cov}((\mathbf{I} - \mathbf{H})\mathbf{y}, (\mathbf{I} - \mathbf{H})\mathbf{y}) \\ &= (\mathbf{I} - \mathbf{H})\text{Cov}(\mathbf{y}, \mathbf{y})(\mathbf{I} - \mathbf{H})' \\ &= (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})' \\ &= \sigma^2(\mathbf{I} - \mathbf{H}), \end{aligned} \tag{1.18}$$

于是, $\text{Var}(e_i) = (1 - h_{ii})\sigma^2, i = 1, \dots, n$ 。

残差

根据式子(1.15), 残差向量还满足以下关系式,

$$\mathbf{X}'\mathbf{e} = \mathbf{0},$$

根据矩阵的乘法法则, 就得到 $\sum_{i=1}^n \mathbf{e}_i = \mathbf{0}$ 以及 $\sum_{i=1}^n \mathbf{e}_i x_{ji} = 0, j = 1, \dots, p$ 的关系式。解释为, 残差的平均值为零, 残差关于每个自变量的加权平均也为零。

误差项方差 σ^2 的无偏估计为 $\hat{\sigma}^2$

$$\hat{\sigma}^2 = \frac{1}{n-p-1} SSE = \frac{1}{n-p-1} \mathbf{e}'\mathbf{e} = \frac{1}{n-p-1} \sum_{i=1}^n e_i^2,$$

课堂练习1: 请同学们推导其无偏性。

影响分析(补充知识)

类似于一元回归分析，回归诊断首先要考残差是否基本满足Gauss-Markov假设，然后还需要做影响分析，即研究那些样本点 (y_i, \mathbf{x}_i^\top) 对估计或者预测有异常大的影响。由此，我们考虑用以下记号表示剔除第 i 个样本点的线性回归模型

$$\mathbf{y}_{(i)} = \mathbf{X}_{(i)}\boldsymbol{\beta} + \mathbf{e}_{(i)},$$

将从这个模型求到的 $\boldsymbol{\beta}$ 的最小二乘估计记为 $\hat{\boldsymbol{\beta}}_{(i)}$ ，则

$$\hat{\boldsymbol{\beta}}_{(i)} = (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{y}_{(i)},$$

显然向量 $\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)}$ 的模反映了第 i 个样本点对回归系数估计的影响大小，但是简单的模会受到 $\hat{\boldsymbol{\beta}}$ 的协方差矩阵影响，因此需要考虑它的一种标准的数量化函数，Cook 统计量就是其中应用最广泛的一种，其定义如下，

$$D_i = \frac{(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})^\top \mathbf{X}^\top \mathbf{X} (\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})}{p \hat{\sigma}^2}, i = 1, \dots, n, \quad (1.19)$$

影响分析(补充知识)

但是Cook统计量的定义式(1.19)十分不方便计算,要计算n个Cook统计量,需要做n+1次回归,计算量大。下面的定理不仅提供了计算 D_i 的简便公式,也从理论上推导了 D_i 与学生化残差 r_i 还有杠杆值 h_{ii} 之间的关系。根据(1.18),学生化残差定义为

$$r_i = \frac{\hat{e}_i}{\hat{\sigma}\sqrt{1-h_{ii}}}, i = 1, \dots, n.$$

Theorem 7

式(1.19)定义的统计量 D_i 与学生化残差 r_i 和杠杆值 h_{ii} 恰有如下关系

$$D_i = \frac{1}{\rho} \left(\frac{h_{ii}}{1-h_{ii}} \right) r_i^2, i = 1, \dots, n, \quad (1.20)$$

这里 h_{ii} 就是帽子矩阵 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ 的对角元。

影响分析(补充知识)

定理(7)的证明需要用到下面的引理

Lemma 1

设 \mathbf{A} 为 $n \times n$ 可逆矩阵, \mathbf{u}, \mathbf{v} 都是 $n \times 1$ 列向量, 若 $(\mathbf{A} - \mathbf{u}\mathbf{v}')$ 可逆, 则有以下恒等式

$$(\mathbf{A} - \mathbf{u}\mathbf{v}')^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}'\mathbf{A}^{-1}}{1 - \mathbf{u}'\mathbf{A}^{-1}\mathbf{v}}.$$

请同学们验证该引理成立。

定理(7)的证明:

$X'X$ 的讨论

求解 $\hat{\beta}$ 的时候，要求 $(X'X)^{-1}$ 必须存在，这就是要求以下充分必要条件存在

- 1 $|X'X| \neq 0$, 非奇异矩阵
- 2 $\text{rank}(X'X) = p + 1$, 满秩矩阵
- 3 $\text{rank}X = p + 1$

以及必要条件 $n \geq p + 1$ 。

在本课程里，其实还要假设 p 为常值，而 n 可以趋于无穷大。

MLE

如果正态分布假设满足,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

则 \mathbf{y} 的概率分布为: $\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$, 这是似然函数为

$$L(\boldsymbol{\beta}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right\}$$

对其做“ $-\ln$ ”变换, 记为 $\ell(\boldsymbol{\beta})$, 可以证明 $\boldsymbol{\beta}$ 的极大似然估计 $\hat{\boldsymbol{\beta}}_{MLE}$ 与最小二乘估计等价。而误差项的方差 σ^2 的极大似然估计

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} SSE = \frac{1}{n} \mathbf{e}'\mathbf{e},$$

是有偏估计, 在 $n \rightarrow \infty$ 的情况下, 它是渐近无偏估计。

性质

Property 1

$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ 是一个线性估计，即它是 \mathbf{y} 的线性变换。

Property 2

$\hat{\beta}$ 是 β 的无偏估计。

证明：

$$\begin{aligned} E(\hat{\beta}) &= E\{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}\} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E\mathbf{y} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta = \beta, \end{aligned} \tag{1.21}$$

性质

Property 3

$$D(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

证明:

$$\begin{aligned} D(\hat{\beta}) &= \text{Cov}(\hat{\beta}, \hat{\beta}) \\ &= \text{Cov}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}, (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\sigma^2\mathbf{I}_n\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}, \end{aligned} \quad (1.22)$$

当 $p = 1$ 的时候, 就是一元线性回归模型的情况, 此时

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix}$$

性质

同上， $p = 1$ 时，对 $\mathbf{X}'\mathbf{X}$ 求逆，就可以得到

$$D(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} \text{Var}(\hat{\beta}_0) & \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) & \text{Var}(\hat{\beta}_1) \end{bmatrix}$$

随堂测验一

题目1: 对

$$\hat{\sigma}^2 = \frac{1}{n-p-1} \sum_{i=1}^n e_i^2 = \frac{1}{n-p-1} \mathbf{e}'\mathbf{e},$$

(1). 证明其无偏性。

(2). 在正态分布假定下, 计算 $\text{Cov}(\mathbf{e}, \hat{\beta})$, 从而证明 $\hat{\sigma}^2$ 与 $\hat{\beta}$ 的独立性。

题目2: 在正态分布假定下, 对一元线性回归模型, 构造假设检验

 $H_0 : 2\beta_0 = \beta_1$ v.s. $H_1 : 2\beta_0 \neq \beta_1$ 的检验统计量。(提示: $H_0 : 2\beta_0 - \beta_1 = 0$)

讲解一下答案

性质

Property 4

高斯-马尔科夫(G-M)定理: 假设 $E(\mathbf{y}) = \mathbf{X}\beta$, $D(\mathbf{y}) = \sigma^2 \mathbf{I}_n$ 成立, 则 β 的任一线性函数 $\mathbf{c}'\beta$ 的**最小方差线性无偏估计(BLUE)**为 $\mathbf{c}'\hat{\beta}$, 其中, \mathbf{c} 是任一 $p+1$ 维常值列向量, $\hat{\beta}$ 是 β 的最小二乘估计。

证明*: 假设 $\mathbf{a} = (a_1, \dots, a_n)^\top \in R^n$, $\mathbf{a}'\mathbf{y}$ 为 $\mathbf{c}'\beta$ 的一个线性无偏估计,

性质

此性质说明了最小二乘估计 $\hat{\beta}$ 是理想的估计量，注意以下四点

- 1 取常值向量 \mathbf{c} 的第 j 个分量为1，其余全是零，这时G-M定理表明 $\hat{\beta}_j$ 是 β_j 的最小方差线性无偏估计，以后简记为BLUE。

$$\mathbf{c} = (0, \dots, 1, \dots, 0)^\top$$

- 2 当然可能存在 \mathbf{y} 的非线性函数，其作为 $\mathbf{c}'\beta$ 的无偏估计，比最小二乘估计 $\mathbf{c}'\hat{\beta}$ 有更小的方差。
- 3 也可能存在 $\mathbf{c}'\beta$ 的有偏估计，在某种意义上（比如后面要学的均方误差MSE）比最小二乘估计 $\mathbf{c}'\hat{\beta}$ 更好。
- 4 在正态假设下， $\mathbf{c}'\hat{\beta}$ 是 $\mathbf{c}'\beta$ 的最小方差无偏估计。这时，既不存在 \mathbf{y} 的非线性函数，也不存在 \mathbf{y} 的其他线性函数，作为 $\mathbf{c}'\beta$ 的无偏估计，比最小二乘估计 $\mathbf{c}'\hat{\beta}$ 的方差更小。

性质

Property 5

在G-M假设下，最小二乘估计 $\hat{\beta}$ 与残差向量 \mathbf{e} 不相关，即 $\text{Cov}(\hat{\beta}, \mathbf{e}) = \mathbf{0}$ 。
进一步，在正态假设下， $\hat{\beta}$ 与 \mathbf{e} 独立，从而 $\hat{\beta}$ 与 $SSE = \mathbf{e}'\mathbf{e} = \|\mathbf{e}\|^2$ 独立。

证明：随堂测验

Property 6

当 $\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ 时，则

$$(1) \hat{\beta} \sim N(\beta, \sigma^2 (\mathbf{X}'\mathbf{X})^{-1}); \quad (2) SSE/\sigma^2 \sim \chi^2(n - p - 1).$$

证明：

F检验

在得到多元线性回归方程后，还需要对回归方程进行显著性检验，首先来看回归方程显著性F检验，也就是考察 x_1, \dots, x_p 从整体上对随机变量 y 是否有显著的影响，提出原假设

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

H_0 被接受和拒绝分别代表什么含义。为了建立关于 H_0 检验的F统计量，利用总离差平方和分解式，即

$$\|\mathbf{y} - \bar{y}\mathbf{1}_n\|^2 = \|\mathbf{y} - \hat{\mathbf{y}} + \hat{\mathbf{y}} - \bar{y}\mathbf{1}_n\|^2 = \|\mathbf{y} - \hat{\mathbf{y}}\|^2 + \|\hat{\mathbf{y}} - \bar{y}\mathbf{1}_n\|^2, \quad (1.23)$$

简写为

$$SST = SSE + SSR$$

F检验

构造统计量如下

$$F = \frac{SSR/p}{SSE/(n-p-1)} \quad (1.24)$$

正态假设下, 当 H_0 成立时, $F \sim F(p, n-p-1)$ 分布。F检验还可以推广为对任意的如下 H_0 做检验

$$H_0 : \beta_{j_1} = \beta_{j_2} = \dots = \beta_{j_r} = 0,$$

其中 $r < p$, $\{j_1, j_2, \dots, j_r\}$ 是 $\{1, 2, \dots, p\}$ 的任意真子集(或看成任何一个排列)。那么其实我们是在比较如下两个模型

$$\text{Model1} : y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (1.25)$$

$$\text{Model0} : y = \beta_0 + \beta_{j_{r+1}} x_{j_{r+1}} + \dots + \beta_{j_p} x_{j_p} + \varepsilon \quad (1.26)$$

思考这时 H_0 被接受或者拒绝代表什么含义。

F检验

这时只需要分别计算Model1的残差平方和 SSE_1 以及Model0的残差平方和 SSE_0 , 构造统计量

$$F = \frac{(SSE_0 - SSE_1)/r}{SSE_1/(n-p-1)} \sim F(r, n-p-1) \quad (1.27)$$

前面提到的回归方程的显著性检验 $H_0: \beta_1 = \dots = \beta_p = 0$ 就相当于在比较如下两个模型

$$\text{Model1} : y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \quad (1.28)$$

$$\text{Model0} : y = \beta_0 + \varepsilon \quad (1.29)$$

此时Model0的 SSE_0 就是式(1.23)中Model1的SST(同学们证明一下), 于是在(1.27)中, $F = \frac{SSR/p}{SSE/(n-p-1)}$, 与(1.24)等价。因此(1.24)其实是(1.27)的特例。且这里 r 就是从Model1到Model0减少的变量个数。

F检验

检验 $H_0: \beta_{j_1} = \beta_{j_2} = \dots = \beta_{j_r} = 0$, 其实可以用矩阵形式表达 $H_0: A\beta = \mathbf{0}$, 其中 A 是一个 $r \times p$ 维的矩阵, 其行向量的第 j_k 个位置为 1 其余全是零 $\{(0, \dots, 1, \dots, 0)\}$, $k = 1, \dots, r$.

Example 1

对如下两个模型

$$\text{Model 1: } y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$$

$$\text{Model 0: } y = \beta_0 + \beta_2 x_2 + \beta_4 x_4 + \varepsilon$$

做 F 检验, 就等于对 $H_0: \beta_1 = \beta_3 = 0$ 做检验, 也等价于对 $H_0: A\beta = \mathbf{0}$ 做检验, 其中 $\beta = (\beta_1, \beta_2, \beta_3, \beta_4)'$,

$$A = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

注意, $\text{rank}(A) = 2$.

推广的F检验

对任意 $r \times p$ 维矩阵 A ，且 $r \leq p$ ，如果 $\text{rank}(A) = r$ ，则对 $H_0 : A\beta = \mathbf{0}$ 做检验，其统计量也为

$$F = \frac{(SSE_0 - SSE_1)/r}{SSE_1/(n - p - 1)} \sim F(r, n - p - 1) \quad (1.30)$$

其中 SSE_0 就是在零假设 H_0 成立下的简化模型的残差平方和， SSE_1 就是全模型的残差平方和。 r 就是矩阵 A 的秩，也就是从Model1到Model0减少的参数个数。当 $r = p$ ，即 A 是可逆矩阵时候， $H_0 : A\beta = \mathbf{0}$ 即等价于 $H_0 : \beta = \mathbf{0}$ ，回到了回归方程显著性检验的问题。

推广的F检验

以一个例子来说明如何处理一般的 $H_0 : A\beta = 0$ 检验问题。

Example 2

对犯罪率 y , 老师收集到了 x_1, x_2, x_3 三个解释变量, 样本量为 n 。现在对如下全模型做了回归

$$\text{Model 1 : } y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

请问如何检验 $H_0 : \beta_1 = -\beta_2 = -\beta_3$?

推广的F检验

- 1 第一步, 将 $H_0: \beta_1 = -\beta_2 = -\beta_3$ 写成 $H_0: A\beta = \mathbf{0}$ 的形式, 其中

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & -1 \end{pmatrix}, \quad \beta = (\beta_0, \beta_1, \beta_2, \beta_3)', \quad \mathbf{0} = (0, 0)'$$

- 2 第二步, 计算 $\text{rank}(A) = 2$, 计算 SSE_1 。在假设 H_0 成立的条件下, 即

$$\begin{aligned} y &= \beta_0 + \beta_1 x_1 - \beta_1 x_2 - \beta_1 x_3 + \varepsilon \\ &= \beta_0 + \beta_1 (x_1 - x_2 - x_3) + \varepsilon \\ &= \beta_0 + \beta_1 z_1 + \varepsilon \end{aligned}$$

对 y 关于 z_1 做回归, 并计算 SSE_0 。

- 3 第三步, 构造统计量

$$F = \frac{(SSE_0 - SSE_1)/2}{SSE_1/(n - 3 - 1)},$$

最后做检验并分析结果。

t检验

多元线性回归中，回归方程显著不代表每个解释变量对 y 显著，通过对每个解释变量进行显著性检验，可以剔除一些次要的、可有可无的变量。 $H_0: \beta_j = 0$ 其实也是上面讲的 $H_0: A\beta = 0$ 的特例，因此t检验本来就和广义F检验是等价的。由性质6，

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}),$$

记 $(\mathbf{X}'\mathbf{X})^{-1} = (c_{ij})$, $i, j = 0, 1, 2, \dots, p$, 就有

$$E(\hat{\beta}_j) = \beta_j, \quad \text{Var}(\hat{\beta}_j) = c_{jj}\sigma^2, \quad \hat{\beta}_j \sim N(\beta_j, c_{jj}\sigma^2)$$

于是可以构造t统计量

$$t_j = \frac{\hat{\beta}_j}{\sqrt{c_{jj}\hat{\sigma}^2}} \sim t(n-p-1)$$

其中 $\hat{\sigma}^2 = \sqrt{\frac{1}{n-p-1} \sum_{i=1}^n \mathbf{e}_i^2} = \sqrt{\frac{1}{n-p-1} \|\mathbf{e}\|^2} = \sqrt{\frac{1}{n-p-1} \text{SSE}}$. 并且可以构造 β_j 的置信水平为 $1 - \alpha$ 的置信区间

$$(\hat{\beta}_j - t_{\alpha/2} \sqrt{c_{jj}\hat{\sigma}^2}, \hat{\beta}_j + t_{\alpha/2} \sqrt{c_{jj}\hat{\sigma}^2})$$

t检验

由推广的F检验， $H_0: \beta_j = 0$ 可以通过以下三个步骤

- 1 第一步， $H_0: \beta_j = 0$ 等价于 $H_0: A\beta = 0$ ， A 这里只是一个行向量。
- 2 第二步， $\text{rank}(A) = 1$ ，计算 SSE_1 。然后在 H_0 成立的情况下，相当于在Model1中剔除 x_j 后，做回归，并计算 SSE_0 。
- 3 第三步，构造统计量 $F_j = \frac{(SSE_0 - SSE_1)/1}{SSE_1/(n-p-1)}$ ，最后做检验并分析结果。 F_j 也称为偏F统计量。

拟合优度

多元线性回归中，也可以定义**样本决定系数**为

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

其取值在[0,1]之间，越接近1，拟合效果越好；越接近0，拟合效果越差。与F检验比， R^2 更清楚直观地反应了回归拟合的效果，但并不严谨。另外，称

$$R = \sqrt{R^2} = \sqrt{\frac{SSR}{SST}}$$

为 y 关于 x_1, \dots, x_p 的**样本复相关系数**。也是一种拟合程度的度量，整体地衡量 x_1, \dots, x_p 与 y 的线性关系。

中心化和标准化

为什么要中心化和标准化？

- 1 多元线性回归中，自变量之间单位不同
- 2 数据量大，可能因舍入误差导致计算不准确。舍入误差的产生有两个原因：1.数量级的差别；2.病态矩阵的求逆。看如下R程序结果：

```
> b<-matrix(c(1,0.995,0.995,1),nrow=2)
> a<-matrix(c(1,0.99,0.99,1),nrow=2)
> a
      [,1] [,2]
[1,] 1.00 0.99
[2,] 0.99 1.00
> b
      [,1] [,2]
[1,] 1.000 0.995
[2,] 0.995 1.000
> solve(a)
      [,1] [,2]
[1,] 50.25126 -49.74874
[2,] -49.74874 50.25126
> solve(b)
      [,1] [,2]
[1,] 100.25063 -99.74937
[2,] -99.74937 100.25063
```

中心化

多元线性回归模型的经验回归方程为

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_p x_p, \quad (1.31)$$

此方程经过样本中心 $(\bar{x}_1, \dots, \bar{x}_p; \bar{y})$, 做坐标变换如下,

$$\begin{aligned} x_{ji}^c &= x_{ji} - \bar{x}_j, i = 1, \dots, n; j = 1, \dots, p \\ y_i^c &= y_i - \bar{y}, i = 1, \dots, n, \end{aligned} \quad (1.32)$$

其中 $\bar{y} = 1/n \sum_{i=1}^n y_i$, $\bar{x}_j = 1/n \sum_{i=1}^n x_{ji}$, $j = 1, \dots, p$ 。然后, 经验方程变为

$$\hat{y}^c = \hat{\beta}_1 x_1^c + \dots + \hat{\beta}_p x_p^c, \quad (1.33)$$

中心化

备注:

- 1 中心化经验回归方程的常数项为0，而回归系数的最小二乘估计不变，即 $\hat{\beta}_1, \dots, \hat{\beta}_p$ 不变。
- 2 中心化经验回归方程只包含p个参数，比一般经验回归方程少了一个，在变量较多时，可减少计算工作量（尤其是手工计算）。因此，往往手工计算时，先中心化再估计中心化经验回归方程，再根据

$$\hat{\beta}_0 = \hat{y} - (\hat{\beta}_1 x_1 + \dots + \hat{\beta}_p x_p)$$

求出常数项估计值 β_0 。

- 3 思考题：(1.31)与中心化后的(1.33)的回归系数最小二乘估计不变，但他们的t检验统计量也保持不变吗？试用R程序模拟验证或实证。

标准化

为了消除量纲的不同和数量级的差异所带来的影响，还需要对样本数据作标准化处理，然后用最小二乘估计未知参数。标准化的公式为：

$$x_{ji}^* = \frac{x_{ji} - \bar{x}_j}{\hat{\sigma}_{xj}}; \quad y_i^* = \frac{y_i - \bar{y}}{\hat{\sigma}_y}, \quad i = 1, \dots, n; \quad j = 1, \dots, p \quad (1.34)$$

其中 $\hat{\sigma}_{xj}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$ 是自变量 x_j 的样本方差。标准化后的经验回归方程为，

$$\hat{y}^* = \hat{\beta}_1^* x_1^* + \dots + \hat{\beta}_p^* x_p^*, \quad (1.35)$$

标准化包括中心化，因此标准化的回归常数项为零。另外，请同学们验证，

$$\hat{\beta}_j^* = \frac{\hat{\sigma}_{xj}}{\hat{\sigma}_y} \hat{\beta}_j, \quad j = 1, \dots, p$$

中心化

备注：

- 1 普通最小二乘估计 $\hat{\beta}_j$ 的解释
- 2 标准化回归系数 $\hat{\beta}_j^*$ 的解释
- 3 例子，

$$\hat{y} = \pi + 300x_1 + 3x_2$$

其中 x_1 是以米为单位； x_2 是以厘米为单位。

标准化回归系数，增加了比较变量间相对重要性的可能，但仍需谨慎使用。

样本相关阵

复相关系数 R 反应的是 y 与一组解释变量整体的相关性，是整体和共性指标；简单相关系数反应的是两个变量间的相关性，是局部和个性指标。实践中，应该整体与局部结合、共性与个性结合。

关于复相关系数 R ，其实就是 $(y_i, \hat{y}_i), i = 1, \dots, n$ 的样本相关系数，例子

```
> mod1<-lm(y~M+Ed+U1, data=UScrime)
> y.hat<-fitted(mod1)
> results<-summary(mod1)
> results$r.squared^0.5
[1] 0.3385233
> cor(UScrime$y,y.hat)
[1] 0.3385233
```

Figure 2: 复相关系数 R 的意义（同学们证明）

复相关系数 R 的意义

课堂练习一

证明： 若 $\{\hat{y}_i, i = 1, \dots, n\}$ 是 $\{y_i, i = 1, \dots, n\}$ 做线性回归后的拟合值，则 y 与 \hat{y} 的**样本相关系数** $r_{y\hat{y}}$ 和**回归模型的决定系数** R^2 有如下关系

$$r_{y\hat{y}}^2 = \frac{SSR}{SST} = R^2$$

样本相关阵

由样本观测值 $\{x_{1i}, x_{2i}, \dots, x_{pi}, i = 1, \dots, n\}$, 分别计算 x_j 与 x_k 之间的简单相关系数 r_{jk} , 得自变量样本相关阵

$$\mathbf{r} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix} \quad (1.36)$$

相关阵是对称阵。若记 $\mathbf{X}^* = (\mathbf{x}_1^*, \dots, \mathbf{x}_p^*)_{n \times p}$ 为标准化后的设计矩阵, 则

$$\mathbf{r} = (\mathbf{X}^*)' \mathbf{X}^* / (n - 1)$$

样本相关阵

进一步求出 y 和每个解释变量 x_j 的相关系数 r_{yj} , 得增广样本相关阵

$$\mathbf{r} = \begin{bmatrix} 1 & r_{y1} & r_{y2} & \cdots & r_{yp} \\ r_{1y} & 1 & r_{12} & \cdots & r_{1p} \\ r_{2y} & r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \vdots & \vdots & \\ r_{py} & r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix} \quad (1.37)$$

偏决定系数

若干概念:

- 1 复相关系数 R 是 y 和 \hat{y} 之间的简单相关系数。
- 2 偏相关系数, 是在多元线性回归中, 固定其他变量后, 给定两个变量之间的相关系数。
- 3 研究偏相关系数, 首先研究偏决定系数
- 4 复决定系数 $R^2 = \frac{SST - SSE}{SST}$ 是回归中一组解释变量 x_1, \dots, x_p 使得响应变量 y 的变差被解释掉的相对量。
- 5 偏决定系数则是在回归方程已包含若干解释变量时, 再引入某一个新的变量后, y 的剩余变差被解释掉的相对量, 衡量的是解释变量对 y 变差解释的边际贡献。

以两个解释变量的偏决定系数为例

二元线性回归模型

$$\text{Model1} : y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i, i = 1, \dots, n$$

$$\text{Model0} : y_i = \beta_0 + \beta_2 x_{2i} + \varepsilon_i, i = 1, \dots, n$$

以 $SSE(x_2)$ 表示 Model0 的残差平方和，也就是未被 x_2 解释的 y 的变差。 $SSE(x_1, x_2)$ 则是 Model1 的残差平方和，也是未被 x_1, x_2 解释的 y 的变差。因此，当模型 Model0 已经有 x_2 时，再加入 x_1 使得 y 的剩余变差被解释掉的相对量为：

$$r_{y1;2}^2 = \frac{SSE(x_2) - SSE(x_1, x_2)}{SSE(x_2)} \stackrel{?}{=} \frac{SSR(x_1, x_2) - SSR(x_2)}{SSE(x_2)}$$

偏决定系数一般情况

由此，当模型中已有 $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p$ 时， y 与 x_j 的偏决定系数为：

$$\begin{aligned} r_{yj;-j}^2 &= \frac{SSE(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p) - SSE(x_1, \dots, x_p)}{SSE(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_p)} \\ &= \frac{SSR - SSR(-j)}{SSE(-j)} \end{aligned}$$

偏相关系数

Definition 1

偏决定系数的平方根称为**偏相关系数**，其符号与相应的**回归系数**的符号相同，偏相关系数与回归系数的显著性检验的**t值**是等价的。

对任意 p 个变量 x_1, \dots, x_p 可定义他们之间的偏相关系数。记

$$r_{jk} = \frac{S_{jk}}{\sqrt{S_{jj}S_{kk}}}$$

为 x_j, x_k 之间的简单相关系数， $\mathbf{r} = (r_{jk})_{p \times p}$ 为相关阵，则在固定 x_3, \dots, x_p 不变时， x_1 与 x_2 之间的**偏相关系数**为：

$$r_{12;3,\dots,p} = \frac{-\Delta_{12}}{\sqrt{\Delta_{11}\Delta_{22}}}$$

其中 Δ_{jk} 表示 \mathbf{r} 第 j 行第 k 列元素的**代数余子式**，

总结与评注

- 1 满足多元线性模型的基本假定时，普通最小二乘估计才可靠
- 2 R^2 的大小与 n 和 p 有关， n 和 p 接近时， R^2 容易接近1，此时有虚假成分
- 3 回归方程的显著性检验与推广的F检验的区别和联系。回归方程的显著性检验，当拒绝 H_0 时仍需谨慎，此时可能漏掉了一些重要的自变量；另外，有的回归系数可能并不通过 $H_0: \beta_j = 0$ 的检验（回归系数的t检验）
- 4 回归系数的解释问题，理想和现实两种情况
- 5 实际中，难以避免的问题有，多重共线性，非线性，交互作用。后面的章节专门解决这些问题。